Rapport de Projet : Détection de communautés dans DBLP

Algorithmique 2 (INFO-F-203)

Machado Ozcifci Mikail Zeki (Matricule : 592868)
Nom Prénom 2 (Matricule : 000000)

Année Académique 2025-2026

1 Introduction

Ce projet porte sur l'analyse de la base de données bibliographiques DBLP. L'objectif est d'identifier des communautés d'auteurs en modélisant leurs collaborations sous forme de graphe orienté. Nous nous concentrons sur la détection de Composantes Fortement Connexes (SCC) pour des auteurs ayant co-publié au moins 6 fois. La base de données utilisée est le flux XML de DBLP daté du 01-01-2026.

2 Méthodologie

2.1 Algorithmes et structures de données

— **Traitement Online** : La lecture du fichier XML s'effectue de manière séquentielle via la classe `DblpPublicationGenerator`. Les paires d'auteurs sont comptabilisées dans une `Map<String, Map<String, Integer>>` pour minimiser l'impact mémoire avant filtrage.

— **Détection des SCC** : Nous avons implémenté l'algorithme de Kosaraju. Il utilise deux parcours en profondeur (DFS) successifs : le premier pour déterminer l'ordre de fin de traitement, le second sur le graphe inversé pour extraire les composantes.

— **Calcul du Diamètre** : Pour chaque communauté, nous calculons le diamètre en lançant un parcours en largeur (BFS) depuis chaque nœud membre afin de trouver la plus longue distance entre deux auteurs au sein de la SCC.

2.2 Complexité

Dans le pire des cas, avec V le nombre d'auteurs et E le nombre de co-publications :

— **Temps** : La détection des SCC est en $O(V + E)$. Le calcul du diamètre est en $O(V_{scc} \cdot (V_{scc} + E_{scc}))$ par communauté.

— **Mémoire** : $O(V + E)$ pour stocker les listes d'adjacence et les structures de marquage des nœuds.

3 Résultats

3.1 Top 10 des communautés

Le Tableau 1 présente les caractéristiques des 10 plus grandes communautés identifiées de la tache 2.

Rang	Taille (Membres)	Diamètre
1	[133]	[30]
2	[73]	[35]
3	[38]	[13]
4	[34]	[7]
5	[33]	[6]
6	[30]	[17]
7	[27]	[10]
8	[26]	[12]
9	[23]	[6]
10	[21]	[7]

Table 1 – Analyse structurelle des 10 plus grandes SCC de la tache 2.

3.2 Distribution des tailles

L'histogramme des tailles de communautés suit une progression logarithmique, illustrant la prédominance de très petites structures de collaboration par rapport à quelques grands pôles de recherche. la Figure 1 présente l'histogramme des tailles de communautés.

4 Discussion

— **Limites** : L'implémentation actuelle utilise des objets `String` en mémoire vive pour stocker les noms d'auteurs. Cela limite la montée en charge sur des bases de données plus massives.

— **Optimisations (OpenAlex)** : Pour traiter 120 millions d'auteurs, il serait nécessaire d'indexer les auteurs par des entiers (`int`) et d'utiliser du stockage externe (disque) pour la phase de comptage des paires. Le calcul du diamètre devrait également être approximé pour les très grandes composantes.

5 Conclusion

Ce projet a permis d'extraire des communautés scientifiques cohérentes à partir de DBLP en utilisant des algorithmes de graphes fondamentaux. L'approche par SCC se révèle efficace pour isoler des groupes de chercheurs aux collaborations mutuelles fortes et fréquentes.

```
(Échelle logarithmique : chaque cran représente une progression exponentielle)
Taille    1 | 252098  |
Taille    2 | 6128    |
Taille    3 | 1126    |
Taille    4 | 416     |
Taille    5 | 184     |
Taille    6 | 77      |
Taille    7 | 54      |
Taille    8 | 29      |
Taille    9 | 22      |
Taille   10 | 16      |
Taille   11 | 15      |
Taille   12 | 9       |
Taille   13 | 8       |
Taille   14 | 4       |
Taille   15 | 4       |
Taille   16 | 2       |
Taille   17 | 6       |
Taille   18 | 2       |
Taille   19 | 1       |
Taille   21 | 1       |
Taille   23 | 1       |
Taille   26 | 1       |
Taille   27 | 1       |
Taille   30 | 1       |
Taille   33 | 1       |
Taille   34 | 1       |
Taille   38 | 1       |
Taille   73 | 1       |
Taille  133 | 1       |
```

FIGURE 1 – Distribution des tailles de communautés (sortie brute du programme tache 2).